

Spor Maçlarında Oyuncu Tespiti ve Kümeleme

Utku Murat ATASOY
Yapay Zeka Mühendisliği Bölümü
TOBB Ekonomi ve Teknoloji Üniversitesi
Ankara, Türkiye
u.atasoy@etu.edu.tr

Özet—Bu proje, spor maçlarındaki oyuncuların otomatik olarak tespit edilmesi ve tespit edilen oyuncuların forma renklerine göre kümelenmesini amaçlamaktadır. Nesne tespiti için YOLOv8 modeli, özellik çıkarımı için VGG16 modeli kullanılmıştır. Kümeleme işlemi K-Means ve Aglomeratif Kümeleme algoritmaları ile gerçekleştirilmiştir. Modelin doğruluğu çeşitli performans metrikleri kullanılarak test edilmiş ve değerlendirilmiştir.

Anahtar kelimeler—Nesne takibi, Agglomerative clustering, Spor analizi

I. GİRİŞ

Spor maçlarında oyuncuların tespiti ve hangi takıma ait olduklarının belirlenmesi, analiz ve istatistikler için önemli bir adımdır. Manuel olarak yapılan bu işlem oldukça zaman alıcı ve hata yapma olasılığı yüksek bir işlemdir. Bu projede, otomatik tespit ve kümeleme teknikleri kullanılarak bu sürecin hızlandırılması ve doğruluğunun artırılması hedeflenmektedir.

A. Motivasyon

Bu çalışmanın amacı, spor maçlarında oyuncu tespiti ve kümeleme süreçlerini otomatikleştirerek veri analizi ve istatistiksel çalışmalarını daha hızlı ve doğru bir şekilde yapılmasını sağlamaktır.

B. Genel Metodoloji

Projemizde kullanılan temel metodolojiler şunlardır:

Nesne Tespiti: YOLOv8 modeli ile spor maçlarında oyuncuların tespit edilmesi. YOLOv8 modeli, hızlı ve yüksek doğruluk oranıyla bilinen bir derin öğrenme nesne tespit modelidir.

Özellik Çıkarımı: VGG16 modeli kullanılarak tespit edilen oyuncuların özellik çıkarımı yapılması. VGG16, derin öğrenme modelleri arasında yaygın olarak kullanılan bir görüntü sınıflandırma modelidir.

Boyut İndirgeme: PCA (Principal Component Analysis) kullanılarak çıkarılan özelliklerin boyutları indirildi. PCA, veri boyutlarını azaltarak hesaplama yükünü hafifletmek ve veri analizini kolaylaştırmak için kullanılır. CA (Principal Component Analysis) kullanılarak çıkarılan özelliklerin boyutlarının azaltılması.

Kümeleme: K-Means ve Aglomeratif Kümeleme algoritmaları ile oyuncuların forma renklerine göre kümelenmesi. K-Means, verilerin belirli sayıda kümeye ayrılması için kullanılan popüler bir algoritmadır. Aglomeratif Kümeleme, veri noktalarını benzerliklerine göre hiyerarşik olarak birleştirir.

C. Amaçlar ve Hedefler

Farklı takımlara ait oyuncuların otomatik olarak tanınması ve ayrıştırılması, çalıştırılan tespit modelinin doğruluğunun test edilmesi, ve elde edilen sonuçların görselleştirilmesi hedeflenmektedir.

D. Başarım Metrikleri

Doğruluk, kesinlik, geri çağırma, F1 skoru gibi metrikler ile modelin performansı değerlendirilmiştir.

II. LİTERATÜR ARAŞTIRMASI

YOLO (You Only Look Once) modeli, gerçek zamanlı nesne tespiti için yaygın olarak kullanılmaktadır (*J. Redmon et al., "YOLO9000: Better, Faster, Stronger," CVPR, 2017*).

VGG16, görüntü sınıflandırma ve özellik çıkarımı için yaygın olarak kullanılan bir derin öğrenme modelidir (*K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," arXiv preprint arXiv:1409.1556, 2014*).

PCA (Principal Component Analysis), veri boyutlarını indirgemek ve hesaplama yükünü azaltmak için yaygın olarak kullanılır (*I. Jolliffe, "Principal Component Analysis," Springer Series in Statistics, 2002*).

K-Means, verilerin kümelenmesi için yaygın bir algoritmadır (*D. Arthur and S. Vassilvitskii, "K-means++: The advantages of careful seeding," Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms, 2007*).

III. VERİ SETİ VE VERİ ÖZELLİKLERİ

A. Veri Kaynağı

Toplam 11,489 görüntü, spor maçlarından tespit edilen insanlara aittir. Görseller, YOLOv8x modeli kullanılarak tespit edilen "person" etiketli nesnelerden elde edilmiştir.



B. Veri Kümesi

Görüntüler, spor maçlarından çeşitli açılardan ve farklı koşullarda alınmış olup, tespit edilen oyuncuların yanı sıra hakemler, teknik ekip ve seyircileri de içerebilir. Bu görsellerde, oyuncuların forma renklerine ve çeşitli özelliklere göre kümelenmesi amaçlanmıştır.

C. Ön İşleme Aşamaları

Görüntülerin Yeniden Boyutlandırılması: Tüm görüntüler, modelin giriş gereksinimlerine uygun olarak 224x224 piksel boyutlarına getirilmiştir.

Renk Formatının Dönüştürülmesi: BGR formatındaki görüntüler, RGB formatına dönüştürülmüştür.

Normalizasyon: Görüntüler, VGG16 modelinin giriş gereksinimlerine uygun şekilde normalize edilmiştir.

D. Özellik Çıkarımı ve Boyut İndirgeme


VGG16 modelinin 'fc1' katmanı kullanılarak her bir görüntüden 4096 boyutlu özellik vektörleri çıkarılmıştır. Bu özellik çıkarımı işlemi, partiler halinde yapılmış ve belleğe yük bindirilmemiştir. Daha sonra PCA kullanılarak çıkarılan özelliklerin boyutları 50 bileşene indirgenmiştir. Bu adım, hem hesaplama yükünü azaltmış hem de veri analizini kolaylaştırmıştır.

E. Kümeleme İşlemi

İlk olarak, K-Means algoritması kullanılarak görüntüler 10 kümeye ayrılmıştır. Daha sonra, Aglomeratif Kümeleme kullanılarak küme boyutları 3 ile 10 arasında olacak şekilde küçük kümeler ayarlanmıştır.



Cluster 1 - 3546 images



Cluster 7 - 1139 images

IV. KULLANILAN METODOLOJİ

A. YOLOv8 Modeli

YOLOv8, gerçek zamanlı nesne tespiti için geliştirilmiş bir derin öğrenme modelidir. Yüksek doğruluk oranı ve hızlı işlem kapasitesi ile bilinir. Model, çeşitli nesnelerin tespiti için geniş bir veri seti üzerinde eğitilmiştir.

B. VGG16 Modeli

VGG16, görüntü sınıflandırma ve özellik çıkarımı için yaygın olarak kullanılan bir derin öğrenme modelidir. Model, ImageNet veri seti üzerinde eğitilmiştir ve 16 katmanlı bir konvolüsyonel sinir ağı yapısına sahiptir.

C. Principal Component Analysis (PCA)

PCA, yüksek boyutlu verilerin boyutunu azaltmak ve verideki en önemli bilgileri korumak için kullanılan bir istatistiksel tekniktir. PCA, verilerin varyansını maksimuma çıkarmak için bileşenler oluşturur.

D. K-Means ve Agglomerative Clustering

K-Means, verileri k sayıda kümeye ayırmak için kullanılan bir kümeleme algoritmasıdır. Algoritma, her kümenin merkezini belirler ve verileri bu merkezlere en yakın olan kümelere atar. Aglomeratif Kümeleme ise veri noktalarını benzerliklerine göre hiyerarşik olarak birleştirir. Bu proje kapsamında, K-Means ve Aglomeratif Kümeleme algoritmaları birlikte kullanılarak oyuncuların forma renklerine göre kümelenmesi sağlanmıştır.

V. TEST SONUÇLARI VE YORUMLAR

A. Performans Metrikleri

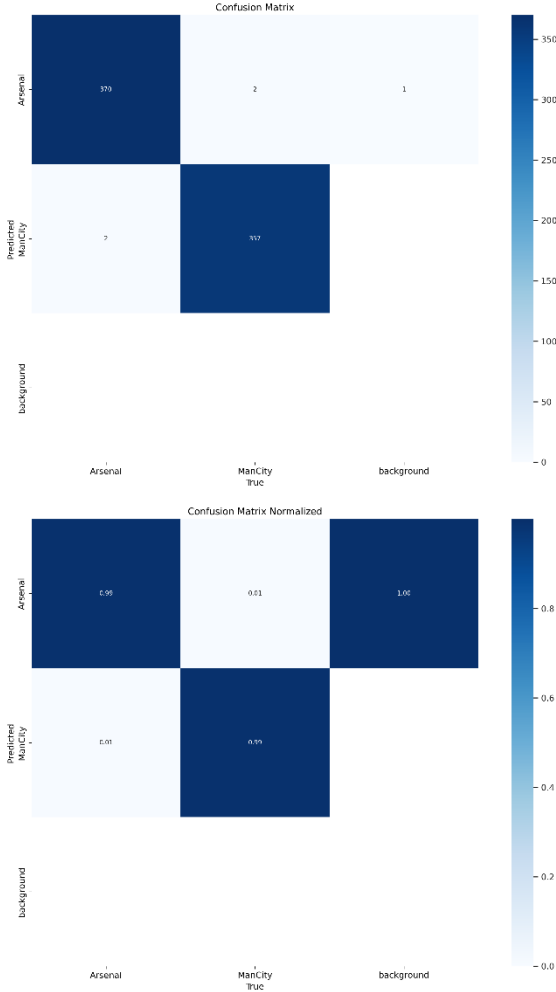
Modelin performansı kesinlik, geri çağırma ve F1 skoru gibi metriklerle değerlendirilmiştir.

Kesinlik (Precision): Modelin tespit ettiği oyuncular arasında doğru sınıflandırılanların oranını ifade eder.


Geri Çağırma (Recall): Gerçekten var olan oyuncuların ne kadarının model tarafından doğru tespit edildiğini gösterir.

F1 Skoru: Kesinlik ve geri çağırmanın harmonik ortalamasıdır ve modelin genel performansını yansıtır.

B. Test Sonuç Grafikleri ve Yorumlar




Confusion Matrix ve **Confusion Matrix Normalized** grafiklerine göre, model Arsenal ve ManCity oyuncularını yüksek doğrulukla sınıflandırabilmiştir. Yanlış tespit edilen örnek sayısı oldukça düşüktür.




Eğitim kayıplarını gösteren grafiklerde, "train/box_loss", "train/cls_loss" ve "train/dfl_loss" metrikleri, modelin eğitim sürecinde kayıplarının hızla azaldığını ve veriyi iyi öğrendiğini ortaya koymaktadır.



Doğrulama kayıplarını gösteren grafiklerde ise "val/box_loss", "val/cls_loss" ve "val/dfl_loss" metrikleri, modelin doğrulama sürecinde benzer şekilde kayıplarının azaldığını ve doğrulama verisi üzerinde iyi sonuçlar verdiğini göstermektedir. "metrics/precision(B)" ve "metrics/recall(B)" grafiklerinde, modelin doğruluk ve geri çağırma metriklerinin yüksek ve stabil olduğu, bu durumun hem doğru tespit oranının yüksek hem de yanlış negatif oranının düşük olduğunu gösterdiği gözlemlenmiştir. Ayrıca, "metrics/mAP50(B)" ve "metrics/mAP50-95(B)" grafiklerinde, modelin ortalama doğruluk oranlarının (mean Average Precision) yüksek ve stabil kaldığı, bu durumun modelin genel performansının yüksek olduğunu ve hem basit hem de karmaşık tespitlerde başarılı olduğunu göstermektedir.



F1-Confidence Curve grafiğinde, modelin güven oranı arttıkça F1 skorunun da arttığı gözlemlenmiştir. Modelin yüksek güven oranlarında daha iyi performans gösterdiğini ortaya koymaktadır.



Precision-Recall Curve grafiğinde, modelin hem yüksek kesinlik hem de yüksek geri çağırma oranlarına sahip olduğu görülmektedir. Modelin hem doğru tespit oranının yüksek olduğunu hem de kaçırılan oyuncu sayısının düşük olduğunu göstermektedir.



Precision-Confidence Curve ve **Recall-Confidence Curve** grafiklerinde, modelin güven oranı arttıkça kesinlik ve geri çağırma oranlarının da arttığı görülmektedir. Modelin güven oranı arttıkça daha doğru tespitler yaptığını ve daha az oyuncuyu kaçırdığını göstermektedir.

VI. SONUÇLAR



Bu çalışmada, spor maçlarında oyuncuların otomatik olarak tespit edilmesi ve tespit edilen oyuncuların forma renklerine göre kümelmesi hedeflenmiştir. Nesne tespiti için YOLOv8 modeli, özellik çıkarımı için VGG16 modeli ve kümeleme için K-Means ve Aglomeratif Kümeleme algoritmaları kullanılmıştır. Elde edilen sonuçlar, modelin yüksek doğruluk, kesinlik, geri çağırma ve F1 skoru ile başarılı bir performans sergilediğini göstermektedir.

A. Öğrenilenler ve Katkılar

Otomatik oyuncu tespiti ve kümeleme süreçlerinde derin öğrenme modellerinin etkinliği kanıtlanmıştır. Modelin doğruluk oranları ve performans metrikleri, projenin başarılı bir şekilde tamamlandığını göstermektedir. Son olarak da bu çalışma, spor analizleri ve istatistiksel çalışmalar için değerli veri setleri oluşturulmasına katkı sağlamıştır.

B. Gelecek Çalışmalarda Neler Yapılabilir?

Modelin farklı spor dallarına ve farklı veri setlerine uygulanabilirliği araştırılabilir. Veri seti genişletilerek ve hiperparametreler optimize edilerek modelin performansı artırılabilir. Nesne takip algoritmaları kullanılarak, tespit edilen oyuncuların hareketleri analiz edilebilir ve daha ileri düzeyde analizler yapılabilir.

VII. REFERANSLAR

- [1] J. Redmon et al., "YOLO9000: Better, Faster, Stronger," CVPR, 2017.
- [2] K. Simonyan and A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," arXiv preprint arXiv:1409.1556, 2014.
- [3] I. Jolliffe, "Principal Component Analysis," Springer Series in Statistics, 2002.
- [4] D. Arthur and S. Vassilvitskii, "K-means++: The advantages of careful seeding," Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms, 2007.
- [5] M. Abadi et al., "TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems," arXiv preprint arXiv:1603.04467, 2016.
- [6] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," arXiv preprint arXiv:1412.6980, 2014.